

پروژه آنالیز بلادرنگ تراکنش‌های بانکی  
و کشف تقلب

آرمین افضلی  
محمد صالح پژند

## فهرست مطالب

۲	۱	مقدمه و شرح پروژه
۲	۱.۱	هدف پروژه
۲	۲.۱	دیتاست
۲	۲	معماری سیستم
۲	۱.۲	جریان داده
۲	۲.۲	اجزای سیستم
۲	۳	گام اول: تولید جریان داده
۲	۱.۳	پیاده‌سازی <i>Kafka Producer</i>
۳	۲.۳	منطق تخصیص کاربر
۳	۳.۳	کد پیاده‌سازی
۳	۴.۳	خروجی تولیدکننده (نتایج واقعی)
۳	۴	گام دوم: پردازش و تحلیل
۳	۱.۴	دسته‌بندی تراکنش‌ها
۴	۲.۴	تشخیص کاربران لیست سیاه ( <i>JOIN</i> )
۴	۳.۴	تشخیص بات با پنجره زمانی ( <i>Windowing</i> )
۴	۵	گام سوم: نمایش نتایج
۴	۱.۵	خروجی تشخیص بات (نتایج واقعی)
۵	۲.۵	آمار کلی (نتایج واقعی)
۵	۳.۵	آمار نهایی
۵	۶	پیاده‌سازی <i>Docker</i>
۵	۱.۶	سرویس‌های کانتینری
۵	۲.۶	دستورات اجرا

## ۱. مقدمه و شرح پروژه

### ۱.۱. هدف پروژه

هدف این پروژه پیاده‌سازی یک پایپلاین کلان‌داده (Big Data Pipeline) است که داده‌های واقعی تراکنش‌های بانکی را به صورت بلادرنگ پردازش کرده و ناهنجاری‌های زیر را شناسایی می‌کند:

- تراکنش‌های مشکوک از کاربران شناخته شده متقلب (User\_Hacker)
- حملات بات (Bot Attack) با استفاده از تحلیل پنجره زمانی
- دسته‌بندی تراکنش‌ها بر اساس مبلغ (Macro/Micro/Normal)
- کاربران لیست سیاه با وضعیت BLOCKED

### ۲.۱. دیتاست

این پروژه از دیتاست Credit Card Fraud Detection از سایت Kaggle استفاده می‌کند:

## ۲. معماری سیستم

### ۱.۲. جریان داده

داده‌ها در این پایپلاین به صورت زیر جریان می‌یابند:

*creditcard.csv* → *Kafka Producer* → *Kafka Topic* → *Spark Streaming* → *Output*

### ۲.۲. اجزای سیستم

توضیحات	کامپوننت
سرویس هماهنگ‌کننده کافکا	<i>Zookeeper</i>
صف پیام توزیع شده با تاپیک <i>bank_transactions</i>	<i>Apache Kafka</i>
اسکرپت پایتون برای خواندن <i>CSV</i> و ارسال با شبیه‌سازی تقلب/بات	<i>Kafka Producer</i>
هماهنگ‌کننده کلاستر اسپارک	<i>Spark Master</i>
اجراکننده تسک‌های پردازشی	<i>Spark Worker</i>
اپلیکیشن <i>Structured Streaming</i> با دسته‌بندی، لیست سیاه و تشخیص بات	<i>Spark Processor</i>

جدول ۱: اجزای معماری سیستم

## ۳. گام اول: تولید جریان داده

### ۱.۳. پیاده‌سازی *Kafka Producer*

اسکرپت تولیدکننده فایل *creditcard.csv* را خط به خط خوانده و تراکنش‌ها را به کافکا ارسال می‌کند.

### ۲.۳. منطق تخصیص کاربر

عمل	User_ID	شرط	سناریو
ارسال یکبار	User_Hacker	Class = 1	تقلب
ارسال ۵ بار متوالی	User_Bot	احتمال ۲٪	حمله بات
ارسال یکبار	User_0001-1000	پیش فرض	عادی

جدول ۲: منطق تخصیص کاربر

### ۳.۳. کد پیاده سازی

```
if transaction_class == 1:
    user_id = 'User_Hacker'
elif random.random() < 0.02:
    user_id = 'User_Bot'
    for i in range(5):
        producer.send(topic, record)
else:
    user_id = random.choice(USER_POOL)
```

### ۴.۳. خروجی تولیدکننده (نتایج واقعی)

```
Connected to Kafka at kafka:29092
FRAUD DETECTED! Transaction TXN_1770283968053 - User: User_Hacker, Amount:
$179.66
BOT ATTACK SIMULATION - Sending 5 rapid transactions
Bot attack completed - User: User_Bot, Amount: $18.13 x 5
Processed 10000 transactions (Normal: 9054, Fraud: 36, Bot Attacks: 182)
```

## ۴. گام دوم: پردازش و تحلیل

### ۱.۴. دسته بندی تراکنش ها

یک ستون جدید به نام Category بر اساس مبلغ تراکنش ایجاد می شود:

توضیحات	شرط	دسته
تراکنش های بزرگ	Amount > \$500	Macro
تراکنش های کوچک	Amount < \$20	Micro
تراکنش های معمولی	\$20 < Amount < \$500	Normal

جدول ۳: دسته بندی تراکنش ها بر اساس مبلغ

```
categorized = stream.withColumn("Category",
    when(col("Amount") > 500, "Macro")
    .when(col("Amount") < 20, "Micro")
    .otherwise("Normal"))
```

## ۲.۴. تشخیص کاربران لیست سیاه (JOIN)

یک DataFrame دستی شامل کاربران لیست سیاه ایجاد شده و با استریم زنده JOIN می‌شود:

```
blacklist_data = [('User_Hacker', 'Known Fraud Actor', '2024-01-01')]
blacklist_df = spark.createDataFrame(blacklist_data, schema)

joined = transactions.join(blacklist_df, on='User_ID', how='left')

result = joined.withColumn('User_Status',
    when(col('Block_Reason').isNotNull(), 'BLOCKED')
    .otherwise('ACTIVE'))
```

## ۳.۴. تشخیص بات با پنجره زمانی (Windowing)

از قابلیت پنجره‌بندی اسپارک برای تشخیص الگوهای فرکانس بالا استفاده می‌شود:

- مدت پنجره: ۱۰ ثانیه (لغزان با فاصله ۵ ثانیه)
- آستانه: بیش از ۴ تراکش در پنجره
- هشدار: BOT\_DETECTED

```
windowed = stream.withWatermark('event_time', '20 seconds')
    .groupBy(
        window(col('event_time'), '10 seconds', '5 seconds'),
        col('User_ID')
    )
    .agg(count('*').alias('transaction_count'))
    .filter(col('transaction_count') > 4)
    .withColumn('Alert_Status', lit('BOT_DETECTED'))
```

## ۵. گام سوم: نمایش نتایج

### ۱.۵. خروجی تشخیص بات (نتایج واقعی)

Batch: 119

window_start	window_end	User_ID	transaction_count	Alert_Status
2026-02-05 09:33:15	2026-02-05 09:33:25	User_Bot	5	BOT_DETECTED
2026-02-05 09:33:10	2026-02-05 09:33:20	User_Bot	5	BOT_DETECTED

## ۲.۵. آمار کلی (نتایج واقعی)

total_transactions	macro_count	micro_count	normal_count	blocked_count	fraud_count	avg_amo
175	4	80	91	1	1	68.33

## ۳.۵. آمار نهایی

مقدار	معیار
+10,300	کل تراکنش‌های پردازش شده
9,327	تراکنش‌های عادی
38	تراکنش‌های تقلبی ( <i>User_Hacker</i> )
187	رویدادهای حمله بات
935	تراکنش‌های بات ( $187 \times 5$ )

جدول ۴: آمار نهایی پردازش

## ۶. پیاده‌سازی Docker

### ۱.۶. سرویس‌های کانتینری

سرویس	ایمیج	کاربرد
<i>zookeeper</i>	<i>cp-zookeeper:7.5.0</i>	هماهنگی کافکا
<i>kafka</i>	<i>cp-kafka:7.5.0</i>	بروکر پیام
<i>spark-master</i>	<i>apache/spark:3.5.0</i>	هماهنگ‌کننده کلاستر
<i>spark-worker</i>	<i>apache/spark:3.5.0</i>	اجراکننده تسک
<i>kafka-producer</i>	<i>Custom Python</i>	استریم داده
<i>spark-processor</i>	<i>apache/spark:3.5.0</i>	پردازش استریم

جدول ۵: سرویس‌های کانتینری

## ۲.۶. دستورات اجرا

```
podman□compose up □d □□build
podman□compose logs □f kafka□producer
podman□compose logs □f spark□processor
podman□compose down □v
```